UNIVERSIDAD EXTERNADO DE COLOMBIA
Programa de Ciencia de Datos

PRIMERA ENTREGA

Predicción de enfermedad cardiovascular: comprensión del artículo base y planteamiento del proyecto

Reproducción y adaptación al contexto colombiano de: Miah, J. et al. (2024). "Improving Cardiovascular Disease Prediction Through Comparative Analysis of Machine Learning Models: A Case Study on Myocardial Infarction".

Integrantes:	Allison Michelle Loango Rayo, Danna Vanessa Caballero Urrego
Curso:	Machine Learning II
Docente:	Wilmer Darío Pineda Ríos
Fecha:	Agosto de 2026

1. Comprensión y sustentación del artículo

1.1 Referencia y contexto del artículo base

El artículo seleccionado es Miah, J., Ca, D. M., Lipu, E. R., Sayed, M. A., Mahmud, F., & Arafat, S. M. Y. (2024). "Improving Cardiovascular Disease Prediction Through Comparative Analysis of Machine Learning Models: A Case Study on Myocardial Infarction". El trabajo se ubica en el campo de la salud digital aplicada a enfermedades no transmisibles y busca demostrar la viabilidad de algoritmos de aprendizaje automático para apoyar el diagnóstico temprano de enfermedad cardiovascular, específicamente del infarto de miocardio (ataque cardíaco), una de las principales causas de mortalidad a nivel mundial.

1.2 Problema que aborda

El artículo aborda un problema de clasificación binaria en salud: predecir si un paciente que ha sufrido insuficiencia cardíaca fallecerá durante el periodo de seguimiento clínico (variable DEATH_EVENT), a partir de un conjunto de 12 características clínicas y demográficas registradas en el momento de la atención (edad, sexo, anemia, diabetes, tabaquismo, presión arterial alta, fracción de eyección, creatinina fosfoquinasa, creatinina sérica, sodio sérico, plaquetas y tiempo de seguimiento). El problema es relevante porque una predicción temprana y precisa permite priorizar intervenciones médicas y reducir la mortalidad evitable.

1.3 Método empleado

La metodología del artículo comprende cinco etapas principales, ilustradas por los propios autores en su Figura 1 (Overview of the study):

1. Recolección de datos: 600 registros de pacientes con insuficiencia cardíaca, reunidos manualmente en cinco clínicas y hospitales de Dhaka, Bangladesh (Square Hospital, National Heart Foundation Hospital, Crescent Hospital, Apollo Hospital y Farida Clinic), cada uno con 13 atributos (12 predictores y 1 variable objetivo).
2. Preprocesamiento: uso de WEKA 3.8.3 para imputar valores faltantes mediante media, mediana y moda, y aplicación de un filtro de selección aleatoria ("Randomly Select") para completar datos sin afectar sustancialmente el desempeño computacional.
3. Selección de variables y validación: uso de RapidMiner para el preprocesamiento, la visualización y la validación de los modelos, con un esquema de validación hold-out (el artículo reporta 80% de entrenamiento y 30% de prueba, una inconsistencia aritmética que se señala más adelante) complementado con validación cruzada de 10 particiones (10-fold cross-validation).
4. Modelamiento: entrenamiento y comparación de seis algoritmos de clasificación — Regresión Logística, Máquinas de Vector de Soporte (SVM), Árbol de Decisión, Bagging, XGBoost y LightGBM — todos ellos con fundamento en técnicas de ensamble y boosting para los últimos cuatro.
5. Evaluación: cálculo de exactitud (accuracy), precisión, sensibilidad (recall), F1-Score y área bajo la curva ROC (AUC) para cada modelo, presentados en la Tabla III del artículo y visualizados mediante curvas ROC por pliegue (Figura 3).

1.4 Supuestos principales

- Los datos faltantes se pueden imputar de forma válida mediante medidas de tendencia central (media, mediana, moda), lo que supone un mecanismo de pérdida de datos aleatorio (missing at random).
- Las 600 observaciones, recolectadas en un único sistema hospitalario de una ciudad, son representativas del fenómeno clínico que se busca modelar.

- La variable objetivo (DEATH_EVENT) está correctamente etiquetada y no existe un desbalance de clases que requiera tratamiento adicional (el artículo no reporta la proporción de eventos positivos ni técnicas de balanceo).
- Los seis algoritmos son comparables entre sí utilizando las mismas particiones de datos y el mismo conjunto de métricas, sin ajuste diferenciado de costos de error entre falsos positivos y falsos negativos.

1.5 Resultados reportados

La Tabla III del artículo resume el desempeño de los seis modelos evaluados:

Modelo	Accuracy (%)	Precisión (%)	Recall (%)	F1 (%)	AUC (%)
Regresión Logística	81.0	83.00	78.6	78.90	88.0
SVM	75.0	72.04	81.1	75.80	87.0
XGBoost	92.7	87.00	81.0	83.90	91.0
LightGBM	90.6	86.30	81.9	84.00	93.9
Árbol de Decisión	82.3	75.90	74.7	73.85	75.0
Bagging	83.0	86.96	74.5	74.00	86.0

Tabla 1. Resultados reportados por Miah et al. (2024), Tabla III del artículo original.

XGBoost obtuvo la mayor exactitud (92.7%) y LightGBM el mayor AUC (93.9%), por lo que ambos se destacan como los modelos de mejor desempeño global, mientras que SVM y el Árbol de Decisión mostraron los resultados más bajos.

1.6 Limitaciones identificadas

- Tamaño de muestra reducido (n = 600) proveniente de una única ciudad, lo que limita la generalización externa del modelo a otras poblaciones o sistemas de salud.
- El artículo presenta inconsistencias internas: en el resumen se afirma que XGBoost es el "top-performing model", pero en la introducción se concluye que "LightGBM emerges as the most promising contender"; adicionalmente, la sección de conclusiones atribuye a XGBoost métricas (90.60% de exactitud) que en realidad corresponden a LightGBM según la Tabla III (92.7%). Esta falta de coherencia debe tenerse presente al reproducir el artículo y se documentará explícitamente en el informe.
- La validación reportada mezcla dos esquemas (hold-out "80/30", que no suma 100%, y validación cruzada de 10 pliegues) sin que quede claro cuál se usó finalmente para producir la Tabla III, lo que dificulta la réplica exacta.
- No se reporta el balance de clases de la variable objetivo ni se aplican técnicas de sobremuestreo/submuestreo pese a que en la Figura 1 se menciona una etapa de "Over sampling the dataset".
- Ausencia de pruebas de significancia estadística entre modelos y de un proceso documentado de ajuste de hiperparámetros, lo que limita la solidez de la afirmación de superioridad de un modelo sobre otro.
- Varias variables predictoras (creatinina fosfoquinasa, creatinina sérica, sodio sérico) requieren exámenes de laboratorio especializados que no siempre están disponibles en fuentes administrativas o encuestas poblacionales, lo cual es central para la adaptación de datos que se plantea en la sección 3 de este informe.

2. Planteamiento del problema

2.1 Pregunta de investigación

¿Es posible predecir la presencia de un factor de riesgo cardiovascular mayor —la hipertensión arterial diagnosticada— en población colombiana, a partir de variables clínicas, antropométricas y sociodemográficas disponibles en encuestas de salud oficiales, reproduciendo y adaptando el enfoque comparativo de modelos de aprendizaje automático propuesto por Miah et al. (2024)?

2.2 Tipo de tarea y variable objetivo

Se trata de un problema de clasificación binaria supervisada, igual que en el artículo base. La variable objetivo original (DEATH_EVENT: fallecimiento tras insuficiencia cardíaca) no tiene un equivalente directo disponible como dato abierto individual en Colombia, ya que los registros de mortalidad accesibles públicamente están agregados por localidad, sexo y grupo de edad (ver sección 3). Por ello, se adapta la variable objetivo a HIPERTENSION_DX: diagnóstico autorreportado o medido de hipertensión arterial (Sí/No), manteniendo el espíritu del artículo — predecir un desenlace cardiovascular relevante a partir de variables clínico-demográficas — pero usando el desenlace observable de mayor calidad disponible en fuentes colombianas de acceso público. La hipertensión arterial es, además, uno de los predictores más determinantes en el propio artículo base ("elevated blood pressure amplifies the likelihood of demise following cardiac failure"), lo que justifica su uso como variable objetivo adaptada sin perder relevancia clínica.

2.3 Relevancia en el contexto colombiano y bogotano

Las enfermedades cardiovasculares son también la principal causa de mortalidad en Colombia y en Bogotá. Según el conjunto de datos abiertos de la Secretaría Distrital de Salud, la mortalidad prematura por enfermedad cardiocerebrovascular (30 a 70 años) es objeto de seguimiento anual en la ciudad, en línea con la cifra global citada por los propios autores del artículo (17.9 millones de muertes anuales por enfermedad cardiovascular). Contar con modelos predictivos ajustados a las condiciones sociodemográficas locales —régimen de aseguramiento, estrato socioeconómico, ruralidad, acceso a servicios de salud— puede aportar evidencia útil para la focalización de estrategias de tamizaje temprano en el sistema de salud colombiano, un caso de uso distinto pero complementario al enfoque hospitalario del artículo original.

2.4 Método a reproducir y técnicas del curso a aplicar

Se reproducirá la comparación de los mismos seis modelos empleados en el artículo base — Regresión Logística, SVM, Árbol de Decisión, Bagging, XGBoost y LightGBM — evaluados bajo las mismas cinco métricas (accuracy, precisión, recall, F1-Score y AUC-ROC) y bajo un esquema de validación cruzada estratificada de 10 particiones, corrigiendo la inconsistencia metodológica detectada en el artículo (sección 1.6). Se emplearán las técnicas trabajadas en el curso: modelos lineales generalizados, métodos de ensamble tipo bagging (Random Forest) y boosting (AdaBoost, XGBoost/LightGBM), selección y validación de modelos mediante validación cruzada, y curvas ROC/AUC para la comparación de desempeño, ya cubiertas en los talleres previos del curso de Machine Learning.

3. Estrategia de datos

3.1 Decisión general

El equipo utilizará datos reales, descartando la simulación, dado que existen fuentes oficiales colombianas de acceso público con variables suficientemente cercanas a las del artículo base. Se propone una estrategia de datos combinada: una fuente principal de microdatos individuales para el modelamiento predictivo, y una fuente secundaria de datos agregados de mortalidad para contextualizar y validar la relevancia epidemiológica del problema en Bogotá.

3.2 Fuente principal: Encuesta Nacional de Situación Nutricional — ENSIN 2015

La ENSIN, dirigida por el Ministerio de Salud y el ICBF con apoyo del DANE, es una encuesta poblacional individual que releva indicadores antropométricos y bioquímicos, autorreporte de diabetes mellitus e hipertensión arterial, actividad física, hábito de fumar y variables sociodemográficas, con representatividad regional (incluyendo Bogotá y la región Central). Es la fuente que mejor reproduce la naturaleza clínico-poblacional del artículo original, porque incluye un componente bioquímico (colesterol, glucosa, triglicéridos) en una submuestra de adultos, análogo en espíritu a los biomarcadores de laboratorio usados por Miah et al. (creatinina, sodio sérico).

Variables previstas (mapeo con el artículo base)

Variable del artículo base	Variable adaptada (ENSIN 2015)	Observación
Edad, sexo	Edad, sexo	Disponibles directamente.
Diabetes (booleano)	Diagnóstico autorreportado de diabetes	Disponible directamente.
Tabaquismo (booleano)	Consumo de tabaco (autorreporte)	Disponible directamente.
Presión arterial alta	Presión arterial medida + variable objetivo (hipertensión Dx)	Se usa como variable objetivo adaptada.
Creatinina fosfoquinasa / creatinina sérica / sodio sérico	Colesterol total, HDL, glucosa, triglicéridos (submuestra bioquímica)	No hay equivalente exacto; se sustituye por el panel bioquímico disponible en la submuestra ENSIN.
Anemia	No disponible de forma directa	Se evaluará su exclusión o proxy con hemoglobina si el recurso lo permite.
Plaquetas, tiempo de seguimiento	No aplica (diseño transversal, no longitudinal)	El estudio adaptado es transversal, no de seguimiento clínico; se declara como diferencia estructural frente al artículo base.
— (no existe en el artículo)	Estrato socioeconómico, zona urbana/rural, régimen de afiliación en salud	Variables adicionales de contexto colombiano relevantes para el problema adaptado.

Tabla 2. Mapeo de variables entre el artículo base y la fuente de datos colombiana propuesta.

3.3 Fuente complementaria: datos abiertos de salud de Bogotá

- Mortalidad prematura por enfermedad cardiocerebrovascular en Bogotá D.C. (30 a 70 años) — Secretaría Distrital de Salud, portal Datos Abiertos Bogotá. Serie anual agregada por localidad; se usará para dimensionar la magnitud del problema en la ciudad y como referencia de tasas base al justificar el desbalance de clases esperado.
- Mortalidad en Bogotá D.C. — Secretaría Distrital de Salud. Consolidado de defunciones por causa (lista 105), área de residencia, grupo de edad y sexo; sirve de contraste para verificar la coherencia de la prevalencia observada en la muestra de microdatos con la mortalidad real de la ciudad.

- Como alternativa o ampliación futura, se considera la Encuesta de Salud, Bienestar y Envejecimiento — SABE Colombia 2015-2016 (Ministerio de Salud, n ≈ 23.694 adultos de 60 años o más), que incluye una variable explícita de enfermedad cardiovascular autorreportada (0 a 3 condiciones) junto con comorbilidades, funcionalidad y variables socioeconómicas; útil si el equipo decide enfocar el problema en población adulta mayor.

3.4 Caracterización del conjunto de datos previsto

- Variable objetivo: diagnóstico de hipertensión arterial (binaria: Sí/No), con posibilidad de una variante ordinal si se opta por la fuente SABE (0 a 3 condiciones cardiovasculares).
- Predictores previstos: edad, sexo, diabetes, tabaquismo, actividad física, índice de masa corporal, circunferencia de cintura, colesterol total/HDL/LDL, glucosa, triglicéridos (submuestra bioquímica), estrato socioeconómico, zona urbana/rural y región/departamento (para filtrar el subconjunto de Bogotá o Cundinamarca cuando se requiera el nivel distrital).
- Tamaño esperado: la ENSIN 2015 cubre aproximadamente 44.000 hogares a nivel nacional; el subconjunto bioquímico y el filtro por Bogotá/Cundinamarca reducirán la muestra efectiva a un rango estimado de 1.000 a 3.000 registros, aún muy superior a los 600 registros del artículo base.
- Calidad inicial: fuente oficial con documentación metodológica pública (diseño muestral complejo con factores de expansión), por lo que se deberá considerar el uso de ponderadores muestrales en el análisis exploratorio y, si el curso lo permite, en el modelamiento. Se anticipan datos faltantes en el componente bioquímico (submuestra voluntaria) y posible sesgo de autorreporte en diabetes y tabaquismo, limitaciones que se documentarán de forma análoga a las identificadas en el artículo base.
- Acceso: microdatos descargables públicamente a través del portal de datos abiertos del Estado colombiano (www.datos.gov.co) y del Ministerio de Salud; los conjuntos de mortalidad de Bogotá están disponibles en formato CSV en datosabiertos.bogota.gov.co bajo licencia Creative Commons Attribution 4.0.

4. Plan de modelamiento y línea base

4.1 Modelos avanzados a comparar

Siguiendo el diseño comparativo del artículo base, se entrenarán y compararán los siguientes modelos, todos cubiertos por el curso:

6. Regresión Logística — modelo lineal generalizado de referencia dentro del grupo de modelos "avanzados", usado también como término de comparación directa con el artículo original.
7. Máquina de Vector de Soporte (SVM) — con kernel lineal y radial (RBF), para contrastar fronteras de decisión lineales y no lineales.
8. Árbol de Decisión — modelo interpretable de referencia dentro del grupo de modelos no lineales.
9. Bagging (Random Forest) — método de ensamble por remuestreo bootstrap, ya trabajado en el taller de Random Forest del curso.
10. XGBoost — boosting de gradiente, algoritmo de mejor desempeño reportado en el artículo original.
11. LightGBM — boosting de gradiente basado en histogramas, segundo mejor desempeño reportado en el artículo y de mayor AUC.

4.2 Métrica principal de evaluación

Se propone priorizar el AUC-ROC y el recall (sensibilidad) de la clase positiva (hipertensión = Sí) como métricas principales, por encima de la exactitud global que privilegia el artículo base. La justificación es doble: primero, se anticipa un desbalance de clases moderado en la muestra colombiana (la prevalencia poblacional de hipertensión diagnosticada suele ser minoritaria frente a la población sin diagnóstico), lo que hace que la exactitud sea una métrica engañosa; segundo, en un problema de tamizaje en salud pública el costo de un falso negativo (no identificar a una persona en riesgo cardiovascular) es considerablemente mayor que el de un falso positivo (remitir a una persona sana a un control adicional), por lo que priorizar el recall es clínicamente más responsable. El F1-Score y la precisión se reportarán como métricas secundarias para mantener comparabilidad directa con la Tabla III del artículo original.

4.3 Estrategia de validación

- División estratificada de entrenamiento y prueba (70/30 u 80/20, a definir con datos reales) que preserve la proporción de la variable objetivo, corrigiendo la inconsistencia de particiones detectada en el artículo base (sección 1.6).
- Validación cruzada estratificada de 10 particiones (k = 10) sobre el conjunto de entrenamiento, replicando el esquema declarado por Miah et al. (2024), para la selección de hiperparámetros y la estimación robusta de las métricas.
- Reporte de intervalos de variabilidad (media ± desviación estándar) de AUC entre pliegues, tal como se presenta en la Figura 3 del artículo original.
- De ser viable dentro del alcance del curso, incorporación de los factores de expansión muestral de la ENSIN en la partición de datos, para no distorsionar las proporciones poblacionales reales.

4.4 Modelo de línea base

Como referencia mínima de comparación se construirán dos líneas base, siguiendo lo exigido por la rúbrica:

- Clasificador de mayoría (majority classifier): predice siempre la clase más frecuente de la variable objetivo; establece el piso de desempeño en términos de exactitud.
- Regresión logística simple de nivel Machine Learning I: modelo con un número reducido de predictores clásicos (edad, sexo e índice de masa corporal), sin regularización ni ajuste de hiperparámetros, que sirve como referencia intermedia frente a la cual se medirá la mejora aportada por los modelos avanzados de ensamble.

La mejora de cada modelo avanzado se reportará como la diferencia (en puntos porcentuales) de AUC y de recall frente a ambas líneas base, replicando el tipo de comparación cuantitativa que el artículo original realiza entre sus seis modelos.

Referencias

Miah, J., Ca, D. M., Lipu, E. R., Sayed, M. A., Mahmud, F., & Arafat, S. M. Y. (2024). Improving Cardiovascular Disease Prediction Through Comparative Analysis of Machine Learning Models: A Case Study on Myocardial Infarction.

Ministerio de Salud y Protección Social, ICBF, INS, DANE. (2015). Encuesta Nacional de Situación Nutricional — ENSIN 2015. Documento metodológico.

Ministerio de Salud y Protección Social. (2015-2016). Encuesta de Salud, Bienestar y Envejecimiento — SABE Colombia.

Secretaría Distrital de Salud de Bogotá. Mortalidad prematura por enfermedad cardiocerebrovascular en Bogotá D.C. (30 a 70 años). Portal Datos Abiertos Bogotá. https://datosabiertos.bogota.gov.co/dataset/mortalidad-prematura-por-enfermedad-cardiocerebrovascular-en-bogota

Secretaría Distrital de Salud de Bogotá. Mortalidad en Bogotá D.C. Portal Datos Abiertos Bogotá. https://datosabiertos.bogota.gov.co/dataset/mortalidad-en-bogota-d-c